Исследование векторных баз данных для системы накопления производственного опыта

Крыжановский Глеб

17.03.2026

Ссылка на репозиторий:`https://github.com/Gleb-OG/vector-db-research`

1 Цель исследования

Целью данной работы является сравнение векторных баз данных и методов обработки текста для выбора наиболее подходящего решения и последующей реализации механизма хранения и поиска производственного опыта на основе семантического поиска. В качестве основного подхода используется преобразование текстовых фактов в векторные представления и их хранение в векторной базе данных.

В рамках работы сравниваются следующие системы:

- ChromaDB
- Qdrant
- Pinecone

Сравнение проводится по следующим критериям:

- точность поиска
- время выполнения запроса
- масштабируемость
- поддержка дополнительных методов поиска
- удобство интеграции

Также анализируется влияние различных моделей эмбеддингов и методов предобработки текста.

2 Архитектура решения

Разработанный механизм поиска состоит из нескольких этапов:

1. предобработка текста
2. преобразование текста в embedding
3. сохранение embeddings в векторной базе данных
4. преобразование пользовательского запроса в embedding
5. поиск ближайших векторов

Общая схема работы системы:

$$\text{Факт} \rightarrow \text{Предобработка} \rightarrow \text{Embedding} \rightarrow \text{Векторная БД}$$
$$\text{Запрос} \rightarrow \text{Предобработка} \rightarrow \text{Embedding} \rightarrow \text{Поиск} \rightarrow \text{Топ 10 фактов}$$

Результатом работы системы является список наиболее релевантных фактов, связанных с пользовательским запросом.

3 Используемые модели эмбеддингов

В рамках исследования использовались две модели:

- all-MiniLM-L6-v2
- multilingual-e5-base

3.1 Модель all-MiniLM-L6-v2

Данная модель широко используется в системах семантического поиска благодаря высокой скорости работы и небольшому размеру. Размер выходного вектора составляет всего 384.

Основными преимуществами модели являются высокая скорость генерации embeddings и небольшие вычислительные требования. Недостатком является ограниченная поддержка многоязычных текстов.

3.2 Модель multilingual-e5-base

Модель multilingual-e5-base разработана специально для задач семантического поиска и поддерживает множество языков, включая русский. Размер выходного вектора составляет 768.

Основным преимуществом модели является более высокая точность поиска, особенно для текстов на русском языке. Недостатком является более высокая вычислительная нагрузка.

3.3 Сравнение моделей

Критерий	MiniLM	E5
Размер вектора	384	768
Скорость	высокая	средняя
Поддержка языков	ограниченная	многоязычная
Точность поиска	средняя	высокая

Эксперименты показали, что модель multilingual-e5-base обеспечивает более высокую точность семантического поиска.

4 Методы предобработки текста

Для повышения качества поиска были протестированы три метода предобработки:

- Raw - без обработки текста
- NLP - токенизация и лемматизация
- Добавление тематических тегов

4.1 Raw

Текст используется без изменений. Метод прост в реализации, однако может содержать шум, связанный с морфологическими различиями слов.

4.2 NLP-предобработка

Данный метод включает приведение текста к нижнему регистру, токенизацию и лемматизацию. В теории это позволяет уменьшить влияние морфологических различий и улучшить семантическое сравнение текстов, но в условиях эксперимента выяснилось, что семантическая связность текста фактов и запросов наоборот способствуют более точным ответам. Предположительно причина этому - устройство embedding моделей и то, как они были обучены (обучение проводилось на семантически целостных данных, соответственно, и векторизация проходит точнее с аналогичными данными).

4.3 Добавление тематических тегов

В данном методе к тексту добавляются тематические ключевые слова, описывающие содержание факта. Это усиливает семантический сигнал и повышает вероятность нахождения релевантных документов.

5 Методика эксперимента

Для тестирования была сформирована база из 100 фактов. Каждый факт относится к определённой тематической группе. В одной группе находилось ровно 10 "очевидных" фактов.

Для проверки качества поиска были сформированы тестовые запросы, для которых заранее известны релевантные факты.

В качестве метрики точности использовалась метрика:

$$Precision = \frac{\text{Количество релевантных фактов}}{10}$$

Для каждой базы данных измерялись **точность** поиска и среднее **время** выполнения запроса.

6 Результаты экспериментов

Результаты экспериментов представлены на следующих графиках.

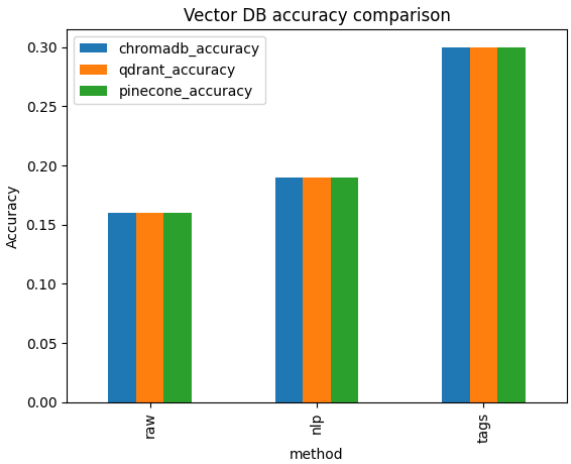

(a) Модель "all-MiniLM-L6-v2"

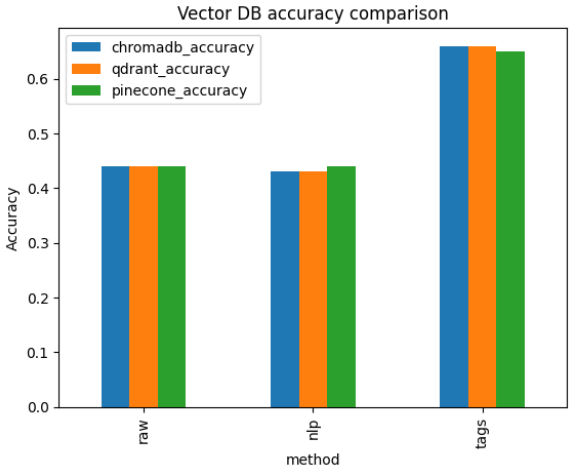

(b) Модель "multilingual-e5-base"

Рис. 1: Результаты измерения точности исследуемых векторных баз данных при различных embedding моделях

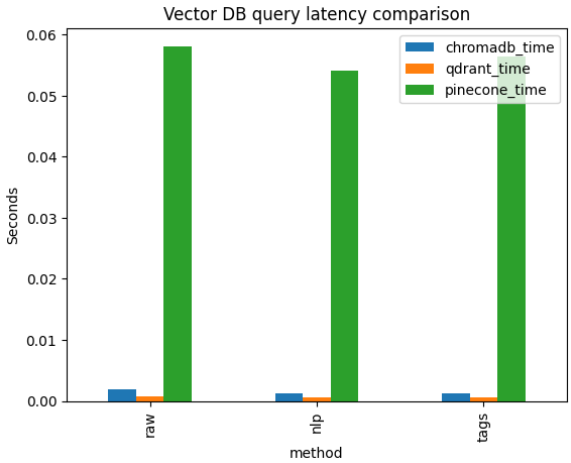

(a) Модель "all-MiniLM-L6-v2"

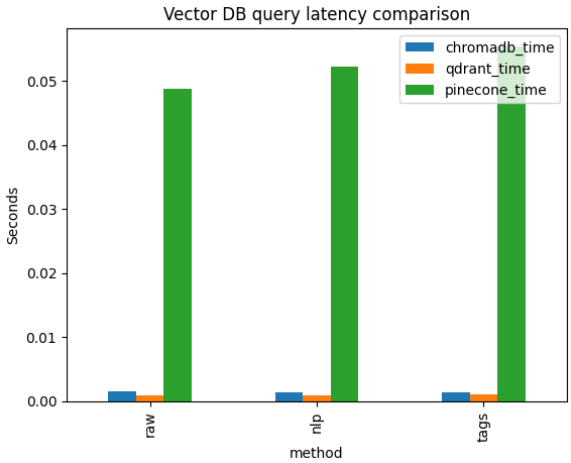

(b) Модель "multilingual-e5-base"

Рис. 2: Результаты измерения скорости выполнения запроса в исследуемых векторных базах данных при различных embedding моделях

7 Сравнение векторных баз данных

Критерий	ChromaDB	Qdrant	Pinecone
Open-source	да	да	нет
Масштабируемость	слабая	высокая	высокая
Фильтрация по метаданным	базовая	расширенная	расширенная
Latency	средняя	низкая	высокая
Развертывание	локальное	локальное/кластер	облако

ChromaDB отличается простотой использования, однако уступает другим системам по производительности и масштабируемости.

Qdrant сочетает высокую производительность, гибкость настройки и возможность локального развёртывания.

Pinecone является мощным облачным решением, однако требует использования внешней инфраструктуры и является платным сервисом.

8 Выбор оптимальной системы

На основании проведённого исследования наиболее подходящей системой является **Qdrant**.

Основные причины выбора:

- высокая точность поиска
- низкое время выполнения запроса
- поддержка фильтрации по метаданным
- высокая масштабируемость
- открытый исходный код

Таким образом, использование базы данных Qdrant в сочетании с моделью embeddings multilingual-e5-base, более медленной по сравнению с all-MiniLM-L6-v2, но дающей значительной прирост в точности, является наиболее эффективным решением для задачи накопления производственного опыта.

9 Заключение

В ходе работы была разработана система семантического поиска по базе производственного опыта. Были исследованы различные модели эмбеддингов, методы предобработки текста и векторные базы данных.

Экспериментальные результаты показали, что использование специализированных моделей эмбеддингов и методов предобработки текста позволяет повысить точность поиска.

Сравнение трёх векторных баз данных показало, что Qdrant обеспечивает наилучший баланс между точностью, производительностью и возможностями масштабирования.